

Владислав Смирнов

Data Engineering Intern

TG @tadzhnahal **Email** theycallmenoir@gmail.com **LinkedIn** linkedin.com/in/vlad-smirnov-in **GitHub** github.com/tadzhnahal

Студент магистратуры ФКН ВШЭ по Data Science с опытом аналитики в бухгалтерском аутсорсе и онлайн-образовании. Сейчас всё глубже двигаюсь в сторону data engineering и делаю проекты, связанные с ETL-пайплайнами, распределённой обработкой данных, backend-сервисами, практиками DevOps и SRE. Больше всего мне интересно разбираться, как data-системы работают под капотом, и учиться делать их устойчивыми и надёжными.

ПРОЕКТЫ

E-commerce ETL

Стек: Python, PostgreSQL, ClickHouse, onETL, PySpark, FastAPI, Celery, Redis, Docker, Kubernetes

Собрал ETL-пайплайн для данных интернет-магазина и выстроил полный маршрут данных от источника до аналитической витрины. Проект загружает данные в PostgreSQL, читает их с помощью onETL и Spark, обрабатывает в Spark и записывает результат в ClickHouse.

1. Разделил пайплайн на полный и инкрементальный проход, вынес оба режима в отдельные Spark job и добавил HWM в YAML-файл. Это позволило отдельно запускать первый full snapshot, повторно прогонять весь набор данных и обрабатывать только новые данные после последней метки.
2. Собрал единые настройки сервиса через config.yaml, .env, ConfigMap и Secret, чтобы один и тот же сервис запускался локально и в Kubernetes без ручной правки параметров перед каждым стартом.
3. Поднял HTTP API на FastAPI и фоновые задачи на Celery с Redis. Через API можно запускать full и incremental ETL, смотреть статус конкретной задачи и хранить историю последних прогонов.
4. Доработал слой обработки, добавил фильтры для бот-активности и вынес чтение источника, трансформации и историю задач в отдельные сервисы, чтобы пайплайн было проще развивать и тестировать.
5. Подготовил два сценария запуска локально через Docker Compose и в Kubernetes через Dockerfile, spark-submit job и набор манифестов для Minikube.

По итогам проекта мне стало понятнее, как собирать ETL-сервис с двумя режимами загрузки, держать конфигурацию в одном месте и отдельно выстраивать локальный и Kubernetes-сценарии запуска.

github.com/tadzhnahal/etl-ecommerce-clickstream

Posts Data Vault

Стек: Python, PostgreSQL, Docker Compose, Data Vault 2.0

Собрал ELT-проект, который забирает данные из REST API, загружает их в слой STG в PostgreSQL и перекладывает в DDS по модели Data Vault 2.0.

1. Поднял локальный PostgreSQL через Docker Compose и подготовил .env для локального запуска, чтобы Python-скрипты и база работали в одном окружении.
2. Создал схемы и таблицы для слоев STG и DDS, чтобы отдельно хранить исходные строки, бизнес-ключи, связи и описательные атрибуты.
3. Написал первый ELT-скрипт, который забирает данные из REST API, очищает таблицу stg.posts и загружает в нее свежий снимок источника вместе с техническими полями.
4. Написал второй ELT-скрипт, который читает STG, считает hash key и загружает данные в hub, link и satellite-таблицы слоя DDS.
5. Разложил id, user_id, title и body по модели Data Vault 2.0 так, чтобы повторный запуск не дублировал одинаковые версии деталей поста и модель оставалась прозрачной по сущностям и связям.

После проекта мне стало понятнее, как собирать простую ELT-цепочку от API до DDS, разделять сущности в Data Vault и не плодить дубли в satellite-таблице.

github.com/tadzhnahal/gazprom-data-vault-posts-task

Flights DWH

Стек: Python, PostgreSQL, Apache Airflow, S3, Jupyter

Собрал свою часть проекта по хранилищу данных для рейсов, где STG-слой принимает исходные файлы, приводит поля к единому виду и загружает данные в PostgreSQL.

1. Подготовил схемы team_vdga_stg и team_vdga_metadata, таблицы flights_raw и airports, а также технический лог etl_load_log, чтобы первый слой хранилища и метаданные жили отдельно.
2. Настроил загрузку справочника аэропортов из файла ourairports.csv в PostgreSQL, чтобы справочные данные попадали в STG вместе с основным потоком.
3. Собрал загрузчик рейсов из S3 в формате csv.gz и сделал его инкрементальным, чтобы в STG попадали новые данные без повторной полной перезагрузки.
4. Подключил шаги загрузки к Airflow, чтобы STG-слой запускался как отдельной частью пайплайна и одновременно встраивался в общий проход по слоям.
5. Проверил результат через SQL и Jupyter: данные появились в STG, ключевые поля не пустые, а лог загрузки совпадает с фактическими строками в таблицах.

Этот проект помог мне лучше понять, как устроен первый слой DWH, зачем ему нужен технический лог и как подготовить STG так, чтобы следующие слои уже не работали с сырыми файлами.

github.com/tadzhnahal/flights-dwh

ОПЫТ

Eduson.tv · Аналитик-методолог июль 2024 — ноябрь 2025

Обязанности: продуктовые исследования, анализ метрик, разработка и доработка IT-курсов.

- Разработал 150+ часов IT-контента по Python, веб-разработке, автотестированию и управлению IT-проектами. В результате за год кластер получил +28% к продуктовому портфелю и вырос вдвое по выручке.
- Провел 15+ съемок с экспертами из Yandex, Sber, Amazon, Booking.com и EPAM. Материалы вошли во все программы кластера.
- Переработал 85% контента бесплатного курса по Python по результатам A/B-тестов и анализа конверсии. Курс принес около 450 тыс. руб. выручки через неделю после запуска.
- Провел 7+ продуктовых исследований новых направлений и помог запустить разработку двух курсов, которые в течение двух недель после запуска сделали более 400% плана по месячной выручке.
- Проанализировал процессы поддержки, выявил ключевые узкие места и разработал фреймворк, который ускорил среднее время ответа на вопрос студента на 60% и сократил расходы на разработку контента на 42%.
- Доработал и запустил дипломные проекты для курсов по веб-разработке, автотестированию, а также стратегическому управлению в IT, один из которых стал одним из флагманов кластера по выручке со средней оценкой студентов 4.6/5.

ООО «Учет и Налоги» · Младший аналитик данных январь 2024 — июль 2024

Обязанности: сверка данных, сбор реестров, проверка клиентских карточек и подготовка управленческой отчетности.

- Собрал единый реестр по 30 клиентам и связал в нем услуги, оплаты, документы и статусы отчетности из 1С, Excel и ЭДО. Руководитель стал быстрее видеть долги, просрочки и клиентов с риском ухода, а команда сократила время на поиск данных на 30%.
- Составил пакет SQL-инструкций с join, group by, case when и подзапросами для сверки оплат, услуг и отчетных периодов. Команда стала быстрее находить неоплаченные счета на 60–90 тыс. руб. в квартал, а доля просроченной дебиторки на рабочем участке снизилась на 12–15%.
- Нашел дубли, пустые поля и ошибки в клиентских карточках и реестрах. Бухгалтеры стали тратить на ручные сверки на 6 часов в неделю меньше и успевали вести больше клиентских задач без потери качества.
- Составил управленческий отчет для руководителя по срокам сдачи и статусам отправки отчетности. Команда стала раньше замечать риск срыва срока, а число срочных задач в конце месяца снизилось на 20%.

ОБРАЗОВАНИЕ

НИУ ВШЭ 2025–2027

Магистратура, прикладная математика и информатика

СПбГУ 2023–2025

Магистратура, медиакоммуникации

ВГУ 2018–2023

Бакалавриат, журналистика

ДОП. ОБРАЗОВАНИЕ

VK Education · Прикладная аналитика данных 2026 — н.в.

Разбираю Big Data, ETL, Data Quality, BI-системы, SQL, Python, скоринг, приоритизацию задач и работу с гипотезами. Курс помогает лучше понимать, как данные проходят путь от источника до решения в продукте.

Изучаю Linux, сети, веб-архитектуру, Docker, Kubernetes, мониторинг сервисов и типовые сбои в инфраструктуре. Курс помогает лучше понимать инфраструктуру прода, увереннее диагностировать сбои и точнее работать с надежностью сервисов.

VK Education
·
Распределенные вычисления

2026
—
н.в.

Изучаю сетевые протоколы, оптимизацию запросов, шардирование и репликацию. Дальше буду изучать NoSQL, Apache Kafka, SRE, observability и нагрузочное тестирование. Курс помогает лучше понимать, как работают высоконагруженные системы и как делать их устойчивыми.

Гринатом
·
Облачные сервисы

2026
—
н.в.

Изучаю облачные сервисы VK Cloud, где на практике работаю с сетями, виртуальными машинами, балансировщиком, Object Storage S3, Managed PostgreSQL, OpenStack и базовой автоматизацией. Программа помогает лучше понимать облачную инфраструктуру, сетевые сценарии и работу сервисов данных в облаке.

ИНСТРУМЕНТЫ

pythonbashsqlpostgresqlclickhouseexcelgooglesheetspandasnumpymatplotlib

seabornpysparkonetlapacheairflowfastapiceleryredisdockerkubernetesansible

terraformopenstackjupyterlinuxgit

ЯЗЫКИ

English

В2

Русский

родной

