

Владислав Смирнов

Data Engineering Intern

TG @tadzhnahal **Email** theycallmenoir@gmail.com **LinkedIn** linkedin.com/in/vlad-smirnov-in **GitHub** github.com/tadzhnahal

Студент магистратуры ФКН ВШЭ по Data Science с опытом аналитики в бухгалтерском аутсорсе и онлайн-образовании. Сейчас всё глубже двигаюсь в сторону data engineering и делаю проекты, связанные с ETL-пайплайнами, распределённой обработкой данных, backend-сервисами, практиками DevOps и SRE. Больше всего мне интересно разбираться, как data-системы работают под капотом, и учиться делать их устойчивыми и надёжными.

ПРОЕКТЫ

ETL E-commerce Clickstream

Стек: Python, PostgreSQL, ClickHouse, onETL, PySpark, FastAPI, Celery, Redis, Docker, Kubernetes

Собрал ETL-пайплайн для данных интернет-магазина и выстроил полный маршрут данных от источника до аналитической витрины. Проект загружает данные в PostgreSQL, читает их с помощью onETL и Spark, обрабатывает в Spark и записывает результат в ClickHouse.

1. Разделил пайплайн на полный и инкрементальный проход, вынес оба режима в отдельные Spark job и добавил HWM в YAML-файл. Это позволило отдельно запускать первый full snapshot, повторно прогонять весь набор данных и обрабатывать только новые данные после последней метки.
2. Собрал единые настройки сервиса через config.yaml, .env, ConfigMap и Secret, чтобы один и тот же сервис запускался локально и в Kubernetes без ручной правки параметров перед каждым стартом.
3. Поднял HTTP API на FastAPI и фоновые задачи на Celery с Redis. Через API можно запускать full и incremental ETL, смотреть статус конкретной задачи и хранить историю последних прогонов.
4. Доработал слой обработки, добавил фильтры для бот-активности и вынес чтение источника, трансформации и историю задач в отдельные сервисы, чтобы пайплайн было проще развивать и тестировать.
5. Подготовил два сценария запуска локально через Docker Compose и в Kubernetes через Dockerfile, spark-submit job и набор манифестов для Minikube.

По итогам проекта мне стало понятнее, как собирать ETL-сервис с двумя режимами загрузки, держать конфигурацию в одном месте и отдельно выстраивать локальный и Kubernetes-сценарии запуска.

github.com/tadzhnahal/etl-ecommerce-clickstream

Data Vault Posts Loader

Стек: Python, PostgreSQL, Docker Compose, Data Vault 2.0

Собрал ELT-проект, который забирает данные из REST API, загружает их в слой STG в PostgreSQL и перекладывает в DDS по модели Data Vault 2.0.

1. Поднял локальный PostgreSQL через Docker Compose, подготовил схемы и таблицы для слоев STG и DDS и настроил окружение для локального запуска.
2. Написал два Python-скрипта: первый загружает свежий снимок данных из REST API в STG, второй переносит строки в DDS и считает hash key для hub, link и satellite-таблиц.
3. Разложил данные по модели Data Vault 2.0 так, чтобы бизнес-ключи, связи и описательные атрибуты лежали отдельно, а повторная загрузка не дублировала одинаковые версии деталей поста.

В ходе проекта мне стало понятнее, как разделять слои STG и DDS, зачем выносить бизнес-ключи и связи в отдельные сущности и как выглядит простая загрузка в Data Vault 2.0.

github.com/tadzhnahal/gazprom-data-vault-posts-task

Flights DWH

Стек: Python, PostgreSQL, Apache Airflow, S3, Jupyter

Собрал первую часть проекта по хранилищу данных для рейсов, где STG-слой принимает исходные файлы, приводит поля к единому виду и загружает данные в PostgreSQL.

1. Настроил загрузку данных о рейсах из S3 и справочника аэропортов из отдельного файла, чтобы следующий слой хранилища работал уже с данными в PostgreSQL, а не с сырыми источниками.
2. Собрал Airflow DAG для запуска загрузки и общего прохода пайплайна, чтобы запуск и порядок шагов были собраны в одном оркестраторе.

3. Проверял результат через SQL и Jupyter, чтобы убедиться, что данные корректно попадают в STG и подходят для следующих слоев хранилища.

Этот проект помог мне лучше понять роль первого слоя хранилища, связь между загрузкой источников и оркестрацией в Airflow и то, как подготавливают базу для следующих слоев DWH.

github.com/tadzhnahal/flights-dwh

HTTP Status Checker Automation

Стек: Python, Docker, Ansible, Linux

Собрал небольшой инфраструктурный проект для автоматизации HTTP-проверок, который включает Python-скрипт, Docker-образ и сценарий запуска через Ansible.

1. Написал Python-скрипт, который отправляет запросы к сервису с разными статус-кодами, пишет ответы в лог и не останавливает весь проход, если один из запросов завершается ошибкой.
2. Собрал Docker-образ с Python и зависимостями, чтобы скрипт запускался в контейнере без ручной подготовки окружения на хосте.
3. Написал Ansible playbook, который готовит Docker, собирает образ, запускает контейнер и проверяет результат по логам.

После проекта мне стало понятнее, как собирать небольшой инфраструктурный сценарий целиком — от Python-скрипта до контейнера и автоматизированного запуска через Ansible.

github.com/tadzhnahal/yadro-infra-platform-task

Reliability Lab

Стек: Python, Bash, Docker, Linux, systemd

Собираю учебный стенд вокруг небольшого сервиса, чтобы на одной базе разбирать эксплуатацию приложения, типовые сбои и базовые SRE-сценарии.

1. Добавил Docker-окружение для локального запуска, вынес инфраструктурные файлы в отдельные каталоги и подготовил стенд, который можно быстро поднять и повторно воспроизвести.
2. Оформил отдельный сценарий со сбоем systemd, чтобы разбирать отказ сервиса, читать логи, находить причину поломки и вручную восстанавливать работу приложения.
3. Разложил проект по слоям app, config, infra/docker, labs/linux/systemd-failure и scripts, чтобы отделить код сервиса, конфиг, инфраструктуру и сценарии.

Проект помогает мне лучше понимать, как воспроизводить сбой сервиса, шаг за шагом разбирать отказ systemd и собирать простой учебный стенд вокруг инфраструктурного сценария. Продолжаю работу над проектом и постепенно добавляю новые сценарии.

github.com/tadzhnahal/reliability-lab

ОПЫТ

Eduson.tv · Аналитик-методолог

июль 2024 — ноябрь 2025

Обязанности: продуктовые исследования, анализ метрик, разработка и доработка IT-курсов.

- Разработал 150+ часов IT-контента по Python, веб-разработке, автотестированию и управлению IT-проектами. В результате за год кластер получил +28% к продуктовому портфелю и вырос вдвое по выручке.
- Провел 15+ съемок с экспертами из Yandex, Sber, Amazon, Booking.com и EPAM. Материалы вошли во все программы кластера.
- Переработал 85% контента бесплатного курса по Python по результатам A/B-тестов и анализа конверсии. Курс принес около 450 тыс. руб. выручки через неделю после запуска.
- Провел 7+ продуктовых исследований новых направлений и помог запустить разработку двух курсов, которые в течение двух недель после запуска сделали более 400% плана по месячной выручке.
- Проанализировал процессы поддержки, выявил ключевые узкие места и разработал фреймворк, который ускорил среднее время ответа на вопрос студента на 60% и сократил расходы на разработку контента на 42%.
- Доработал и запустил дипломные проекты для курсов по веб-разработке, автотестированию, а также стратегическому управлению в IT, один из которых стал одним из флагманов кластера по выручке со средней оценкой студентов 4.6/5.

ООО «Учет и Налоги» · Младший аналитик данных

январь 2024 — июль 2024

Обязанности: сверка данных, сбор реестров, проверка клиентских карточек и подготовка управленческой отчетности.

- Собрал единый реестр по 30 клиентам и связал в нем услуги, оплаты, документы и статусы отчетности из 1С, Excel и ЭДО. Руководитель стал быстрее видеть долги, просрочки и клиентов с риском ухода, а команда сократила время на поиск данных на 30%.
- Составил пакет SQL-инструкций с join, group by, case when и подзапросами для сверки оплат, услуг и отчетных периодов. Команда стала быстрее находить неоплаченные счета на 60–90 тыс. руб. в квартал, а доля просроченной дебиторки на рабочем участке снизилась на 12–15%.

- Нашел дубли, пустые поля и ошибки в клиентских карточках и реестрах. Бухгалтеры стали тратить на ручные сверки на 6 часов в неделю меньше и успевали вести больше клиентских задач без потери качества.
- Составил управленческий отчёт для руководителя по срокам сдачи и статусам отправки отчетности. Команда стала раньше замечать риск срыва срока, а число срочных задач в конце месяца снизилось на 20%.

ОБРАЗОВАНИЕ

НИУ ВШЭ

2025–2027

Магистратура, прикладная математика и информатика

СПбГУ

2023–2025

Магистратура, медиакоммуникации

ВГУ

2018–2023

Бакалавриат, журналистика

ДОП. ОБРАЗОВАНИЕ

VK Education · Прикладная аналитика данных

2026 — н.в.

Разбираю Big Data, ETL, Data Quality, BI-системы, SQL, Python, скоринг, приоритизацию задач и работу с гипотезами. Курс помогает лучше понимать, как данные проходят путь от источника до решения в продукте.

VK Education · DevOps/SRE-инженер

2026 — н.в.

Изучаю Linux, сети, веб-архитектуру, Docker, Kubernetes, мониторинг сервисов и типовые сбои в инфраструктуре. Курс помогает лучше понимать инфраструктуру прода, увереннее диагностировать сбои и точнее работать с надёжностью сервисов.

VK Education · Распределенные вычисления

2026 — н.в.

Изучаю сетевые протоколы, оптимизацию запросов, шардирование и репликацию. Дальше буду изучать NoSQL, Apache Kafka, SRE, observability и нагрузочное тестирование. Курс помогает лучше понимать, как работают высоконагруженные системы и как делать их устойчивыми.

Гринатом · Облачные сервисы

2026 — н.в.

Изучаю облачные сервисы VK Cloud, где на практике работаю с сетями, виртуальными машинами, балансировщиком, Object Storage S3, Managed PostgreSQL, OpenStack и базовой автоматизацией. Программа помогает лучше понимать облачную инфраструктуру, сетевые сценарии и работу сервисов данных в облаке.

ИНСТРУМЕНТЫ

python

bash

sql

postgresql

clickhouse

excel

google sheets

pandas

numpy

matplotlib

seaborn

pyspark

onetr

apache airflow

fastapi

celery

redis

docker

kubernetes

ansible

terraform

openstack

jupyter

linux

git

ЯЗЫКИ

English

B2

Русский

родной

